Pemrosesan Bahasa Alami

Deep Learning for NLP — From RNN to Transformers

Martin Manullang

Institut Teknologi Sumatera
mctm.web.id

2026

OUTLINE

Peta materi pertemuan ini

1. **Rekap & Jembatan dari Sesi Sebelumnya**
2. **Dasar-Dasar Deep Learning**
3. **Word Embedding: Kata Jadi Vektor**
4. **Dari MLP ke Model Sekuensial**
5. **Attention Mechanism**
6. **Transfer Learning & Transformers**
7. **BERT vs DistilBERT**

Capaian Pembelajaran

Yang bisa kamu lakukan setelah sesi ini

1. Memahami mengapa *Deep Learning* lebih unggul dari ML tradisional untuk teks.
2. Mengenal arsitektur **RNN, LSTM, dan BiLSTM** beserta konsep *attention*.
3. Memahami cara kerja **Transformer** dan *fine-tuning* model pre-trained.
4. Mampu melihat perbandingan performa antar model dari kode yang sudah berjalan.

Fokus Kelas Ini

Penjelasan lebih banyak **menggunakan intuisi visual** daripada rumus matematika yang rumit.

Mengapa Deep Learning?

Keterbatasan yang membuat kita perlu naik level

Pada sesi-sesi sebelumnya kita sudah pakai **TF-IDF + SVM** / **PyCaret**.

Ternyata ada beberapa hal yang **tidak bisa** dilakukan pendekatan itu:

- **Tidak peduli urutan kata** — "saya *tidak* suka" vs "saya suka *tidak* ada masalah" dianggap mirip.
- **Tidak paham konteks** — kata "bank" di kalimat "tepi sungai" vs "menabung di bank" dianggap sama.
- **Dimensi fitur meledak** — setiap kata unik menjadi satu kolom; ribuan kata = ribuan kolom.

Mengapa Deep Learning?

Apa yang ditawarkan Deep Learning

Deep Learning menyelesaikan ketiga masalah tadi dengan cara:

- **Belajar representasi sendiri** — model secara otomatis menemukan pola penting dari data, tanpa kita perlu rekayasa fitur manual.
- **Memori urutan** — arsitektur RNN / LSTM "membaca" kata satu per satu sambil mengingat apa yang sudah dibaca.
- **Konteks global** — mekanisme *attention* memungkinkan model melihat seluruh kalimat sekaligus.

Analogi Sederhana

Kalau TF-IDF seperti **kamus kata** yang hanya menghitung frekuensi, maka DL seperti **orang yang membaca** — ia mengerti konteks dan urutan.

TF-IDF: Contoh Representasi

Tiga dokumen, satu matriks fitur

Corpus: `D1: "saya suka kopi"` `D2: "saya suka teh"` `D3: "kopi enak sekali"`

Vocabulary (urutan abjad): `enak` | `kopi` | `saya` | `sekali` | `suka` | `teh`

	`enak`	`kopi`	`saya`	`sekali`	`suka`	`teh`
D1	0	**0.58**	**0.58**	0	**0.58**	0
D2	0	0	**0.58**	0	**0.58**	**0.58**
D3	**0.58**	**0.58**	0	**0.58**	0	0

- Setiap **baris** = satu dokumen; setiap **kolom** = satu kata.
- Nilai > 0 hanya untuk kata yang *muncul* di dokumen tersebut.
- D1 dan D3 sama-sama punya kata `kopi` $\Rightarrow$ ada sedikit kemiripan.
- Tapi `suka` dan `enak` yang bermakna mirip? **Tidak terhubung sama sekali.**

Kelemahan TF-IDF #1

Tidak Paham Makna (Semantik)

TF-IDF hanya melihat **kata yang persis sama** — bukan maknanya.

Kalimat A

```
mobil mogok di jalan
```

Kalimat B

```
kendaraan rusak di jalanan
```

Masalah

Tidak ada satu pun kata yang sama $\Rightarrow$ TF-IDF menganggap kedua kalimat **tidak berkaitan sama sekali**, padahal maknanya hampir identik.

Akar penyebab: TF-IDF tidak mengenal *sinonim* — “mobil” $\neq$ “kendaraan”, “mogok” $\neq$ “rusak”.

Kelemahan TF-IDF #2

Tidak Paham Konteks

Satu kata bisa punya makna **berbeda** tergantung konteks kalimat.

Konteks Keuangan

`bank tempat menyimpan uang`

Konteks Alam

`bank sungai yang curam`

Masalah

Kata **"bank"** mendapat skor TF-IDF yang **sama persis** di kedua kalimat, padahal artinya berbeda sama sekali.

TF-IDF memperlakukan token sebagai simbol tanpa makna — kata dikodekan sebagai angka, tidak pernah diinterpretasi berdasarkan lingkungannya.

Kelemahan TF-IDF #3

Sparse & Boros Memori

Ukuran vektor TF-IDF = ukuran *vocabulary* seluruh corpus.

- Vocabulary 50.000 kata ⇒ setiap dokumen menjadi **vektor sepanjang 50.000**.
- Mayoritas nilainya **nol** karena kata-kata tersebut tidak muncul di dokumen itu.

```
[0, 0, 0, 0, 0.3, 0, 0, 0, 0, 0, 0.5, 0, 0, ...]
↑ 99% nilainya nol
```

Dampak Praktis

Dataset 100.000 dokumen × 50.000 fitur = **5 miliar sel** — sebagian besar kosong. Dataset besar ⇒ memori sistem bisa habis.

Kelemahan TF-IDF #4

Tidak Paham Urutan Kata & Out-of-Vocabulary

(a) Urutan kata diabaikan sepenuhnya (*bag of words*):

```
anjing menggigit orang
```

```
orang menggigit anjing
```

Kata sama, frekuensi sama ⇒ **vektor identik** — padahal maknanya sangat berbeda.

(b) Out-of-Vocabulary (OOV) — vocabulary dibekukan setelah training:

```
Vocab:  ["kopi", "teh", "susu"]
Dokumen baru:  "saya suka americano"
↑ tidak dikenal ⇒ diabaikan
```

Ringkasan: Kelemahan TF-IDF

Mengapa kita perlu pendekatan yang lebih canggih

Kelemahan	**Akibat**
Tidak paham sinonim	Kalimat mirip dianggap tidak berkaitan
Tidak paham konteks	Kata ambigu salah diinterpretasi
Sparse vector	Boros memori, komputasi lambat
Abaikan urutan kata	Makna struktural hilang
Out-of-Vocabulary	Kata baru diabaikan total

Semua kelemahan ini dijawab oleh **Word Embedding** — representasi *dense* yang paham sinonim, urutan, dan konteks.

Disclaimer Dataset

Peringatan Konten Sensitif

Dataset yang digunakan pada sesi ini berisi teks seputar **kesehatan mental** — termasuk topik depresi, kecemasan, dan pikiran bunuh diri.

Dataset ini diambil dari sumber publik dan digunakan **semata-mata untuk tujuan edukasi** penelitian Pemrosesan Bahasa Alami.

Jika kamu merasa terganggu dengan konten ini, silakan sampaikan ke pengajar.

Rekap & Jembatan dari Sesi Sebelumnya

Pipeline Traditional ML

Cara kerja yang sudah kita kenal

Setiap langkah dikerjakan **secara manual** oleh programmer:

- **Fitur dibuat manual**: kita yang memilih cara merepresentasikan teks (TF-IDF, BoW).
- **Model hanya belajar dari fitur tersebut** — bukan dari teks aslinya.

Pipeline Deep Learning

Cara kerja yang akan kita pelajari hari ini

Model **belajar sendiri** cara terbaik merepresentasikan teks:

- **Embedding** menggantikan TF-IDF — representasi kata *dipelajari* oleh model.
- **Neural Network** sekaligus menjadi ekstraktor fitur *dan* klasifier.

Perbandingan Pipeline: ML vs. DL

Di mana letak perbedaan utamanya?

Traditional ML

- Fitur **dibuat manual** (TF-IDF)
- Tidak peduli **urutan kata**
- Interpretasi lebih **mudah**
- Butuh **data lebih sedikit**
- Training **cepat**

Deep Learning

- Fitur **dipelajari otomatis**
- Memahami **urutan & konteks**
- Model lebih **kompleks**
- Butuh **data lebih banyak**
- Training **lebih lama**

$\Rightarrow$ Tidak ada yang selalu lebih baik — pilihan tergantung data, waktu, dan kebutuhan.

Dari Fitur Manual ke Representasi Terpelajar

Lompatan konseptual terbesar dalam Deep Learning

TF-IDF (Fitur Manual)

Setiap kata menjadi satu kolom angka.

Kata	dok.1	dok.2
`sedih`	0.42	0.00
`cemas`	0.00	0.55
`senang`	0.10	0.33

Kata yang mirip maknanya **tidak** saling terkait.

Word Embedding (Terpelajar)

Setiap kata menjadi **vektor kontinu** berdimensi kecil.

Kata	dim-1	dim-2
`sedih`	-0.8	$+0.3$
`cemas`	-0.7	$+0.4$
`senang`	$+0.9$	-0.2

`sedih` dan `cemas` **berdekatan** di ruang vektor karena maknanya mirip.

Dataset: Dari Sesi 1 ke Sesi Ini

Mengapa kita ganti dataset?

Sesi 1 — Indonesian Chat

- Bahasa Indonesia
- 2 kelas: *toxic* vs *non-toxic*
- Klasifikasi sederhana
- Cocok untuk ML tradisional

Sesi Ini — Mental Health Sentiment

- Bahasa Inggris
- **7 kelas** emosi/kondisi mental
- Nuansa makna sangat halus
- Membutuhkan pemahaman **konteks**

Dataset dengan 7 kelas yang mirip maknanya menjadi **alasan kuat** mengapa kita perlu metode yang lebih canggih dari TF-IDF.

Sekilas Dataset: Mental Health Sentiment

7 Kelas Label yang Akan Kita Prediksi

#	Label	Deskripsi Singkat
1	`Normal`	Teks tanpa indikasi kondisi mental tertentu
2	`Depression`	Ekspresi rasa sedih, putus asa, tidak berdaya
3	`Suicidal`	Pikiran atau niatan menyakiti diri
4	`Anxiety`	Kekhawatiran berlebih, rasa takut, panik
5	`Bipolar`	Perubahan suasana hati ekstrem (senang↔sedih)
6	`Stress`	Tekanan hidup, beban pikiran
7	`Personality Disorder`	Pola pikir atau perilaku yang tidak biasa

Tantangan: Banyak kelas yang sulit dibedakan — misalnya `Depression` vs `Suicidal`. Inilah yang membuat tugasnya menarik!

Dasar-Dasar Deep Learning

Neuron: Unit Terkecil Deep Learning

Meniru cara kerja sel saraf di otak

Bayangkan neuron seperti **saklar cerdas**: ia menerima beberapa sinyal, menimbang-nimbangnya, lalu memutuskan apakah harus "menyala" atau tidak.

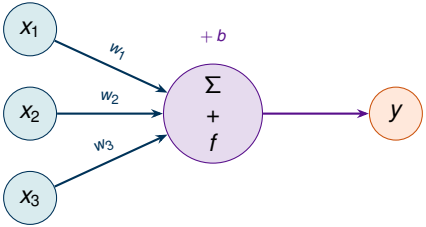

- x_1, x_2, x_3 = **input**, w_1, w_2, w_3 = **weight** (bobot kepentingan)
- b = **bias** (pergeseran ambang), f = **fungsi aktivasi**
- Rumus: $y = f\left(w_1 x_1 + w_2 x_2 + w_3 x_3 + b\right)$

Weight & Bias: Parameter yang Dipelajari

Model belajar = model menyetel angka-angka ini

Weight (w)

- Menentukan **seberapa besar pengaruh** suatu input
- w besar $\rightarrow$ sangat berpengaruh
- w negatif $\rightarrow$ bersifat "menghambat"

Bias (b)

- Menggeser titik keputusan neuron
- Neuron bisa aktif meski semua input = 0
- Seperti b dalam $y = mx + b$

Inisialisasi Weight

Dimulai dari nilai acak kecil. Metode umum: **Xavier** atau **He initialization**. Nilai disesuaikan bertahap selama training.

Fungsi Aktivasi

Memberi kemampuan "berpikir non-linear" pada neuron

Tanpa fungsi aktivasi, seluruh jaringan hanya melakukan operasi linear.

Fungsi	Rentang Output	Kapan digunakan
ReLU	$[0, \infty)$	Hidden layer — paling umum, komputasi cepat
Sigmoid	$(0, 1)$	Output layer klasifikasi *biner*
Tanh	$(-1, 1)$	Hidden layer RNN / LSTM — mengatasi batasan Sigmoid
Softmax	$(0, 1)$, jumlah = 1	Output layer klasifikasi *multikelas*

Analogi ReLU

ReLU ($\max(0, x)$) seperti lampu yang hanya menyala saat ada listrik positif — nilai negatif $\rightarrow$ tetap 0.

Grafik Fungsi Aktivasi

Visualisasi singkat bentuk masing-masing fungsi

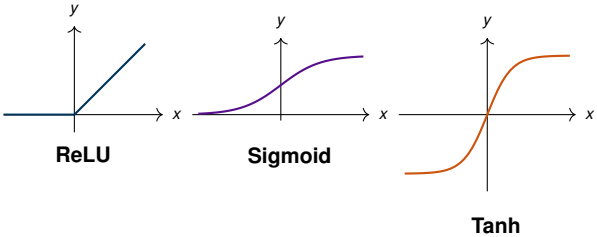

Softmax tidak digambar di sini karena ia bekerja pada *vektor* (bukan satu angka) — mengubah sekumpulan skor menjadi distribusi probabilitas yang totalnya = 1.

Layer: Menyusun Neuron Menjadi Jaringan

Konsep *depth* dalam Deep Learning

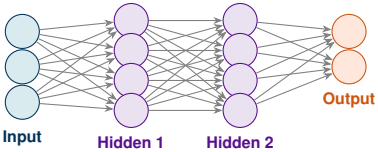

- **Input layer**: menerima data mentah (teks yang sudah di-encode)
- **Hidden layer**: mengekstrak pola — makin banyak layer, makin *dalam*
- **Output layer**: menghasilkan prediksi (7 kelas $\rightarrow$ 7 neuron output)

Loss Function: Mengukur Seberapa Salah Model

Sinyal yang memberi tahu model "kamu masih keliru"

Loss function mengukur selisih prediksi model vs. jawaban benar. Makin kecil *loss*, makin bagus.

Cross-Entropy Loss — Klasifikasi Multikelas

$$\mathcal{L} = -\sum_{c=1}^{C} y_c \cdot \log(\hat{p}_c)$$

- $y_c = 1$ jika kelas c benar, 0 jika tidak
- $\hat{p}_c$ = probabilitas prediksi untuk kelas c (output Softmax)

Contoh

Jawaban: `Anxiety`. Prediksi `Anxiety` 90% → loss kecil. Prediksi `Normal` 90% → loss besar.

Feedforward Network (MLP)

Neural network paling sederhana — data mengalir satu arah

MLP (*Multi-Layer Perceptron*) adalah jaringan saraf di mana data bergerak **hanya dari kiri ke kanan** — tidak ada putaran balik.

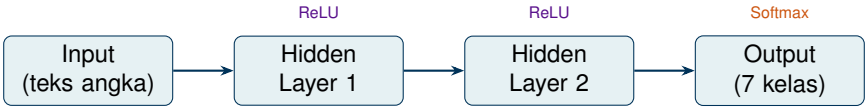

Kelebihan MLP:

- Sederhana dan cepat dilatih
- Cocok untuk data tabular

Kekurangan untuk Teks:

- Tidak mempertimbangkan **urutan kata**
- Inilah yang nanti diselesaikan RNN

Overfitting: Model Terlalu "Hafal"

Masalah klasik yang sering muncul saat melatih model

Overfitting terjadi ketika model terlalu fokus menghafal data latih, sehingga performa di data baru (data uji) justru buruk.

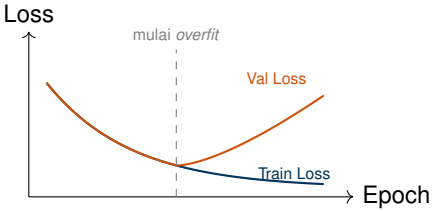

Saat *val loss* mulai naik sementara *train loss* terus turun, itulah tanda overfitting.

Regularisasi: Cara Mencegah Overfitting

Tiga teknik yang paling sering digunakan

Dropout

Saat training, sebagian neuron **dimatikan secara acak** di setiap iterasi.

Memaksa model tidak bergantung pada neuron tertentu saja.

Contoh: `Dropout(0.3)` $\rightarrow$ 30% neuron dimatikan tiap langkah.

L2 Regularization

Menambahkan **penalti** pada nilai weight yang terlalu besar ke dalam loss function.

Weight besar $\rightarrow$ model mengandalkan fitur tertentu secara berlebihan.

Disebut juga *weight decay*.

Early Stopping

Hentikan training **saat val loss mulai naik**, bukan saat mencapai epoch maksimum.

Parameter: `patience=3` $\rightarrow$ training berhenti jika val loss tidak membaik selama 3 epoch berturut-turut.

Word Embedding: Kata Jadi Vektor

Dari Kata ke Angka

One-Hot Encoding: cara paling polos

Komputer tidak bisa membaca teks — kita harus mengubah setiap kata menjadi **angka** dulu. Cara paling sederhana: **One-Hot Encoding**. Vocab = [`anjing`, `kucing`, `ikan`, `burung`]

Kata	anjing	kucing	ikan	burung
`anjing`	**1**	0	0	0
`kucing`	0	**1**	0	0
`ikan`	0	0	**1**	0
`burung`	0	0	0	**1**

Masalah

- **Semua kata sama jauhnya**: jarak `anjing`–`kucing` = jarak `anjing`–`ikan`, padahal keduanya sama-sama hewan peliharaan.
- **Sparse**: 50.000 kata ⇒ vektor 50.000 elemen, hampir semuanya nol.

Ide Word Embedding

Kata yang mirip maknanya → posisi yang berdekatan

Bayangkan kamu bisa **memetakan** setiap kata ke sebuah titik di ruang koordinat.
Kata yang maknanya dekat ⇒ titiknya juga dekat.

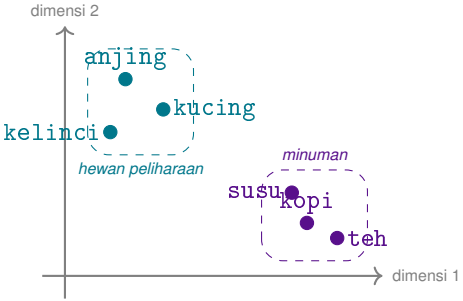

Ini baru **2 dimensi** supaya mudah divisualisasikan.
Dalam praktik, satu kata biasanya direpresentasikan dalam **100–300 dimensi**.

Kata sebagai Koordinat Multi-Dimensi

Tiap dimensi menangkap satu aspek makna

Setiap kata direpresentasikan sebagai **daftar angka** (vektor):

Kata	d_1	d_2	d_3	d_4	d_5	...
`raja`	0.82	-0.41	0.03	0.71	0.55	...
`ratu`	0.79	-0.38	0.02	-0.69	0.52	...
`pria`	0.45	-0.90	0.01	0.66	0.20	...
`wanita`	0.43	-0.87	0.00	-0.64	0.21	...
`kopi`	-0.10	0.12	0.89	0.05	-0.30	...

- Dimensi-dimensi ini **tidak diberi nama** oleh manusia — model yang menemukan sendiri.
- Bisa saja d_4 menangkap "jenis kelamin", d_1 menangkap "jabatan" — kita tidak tahu persis.
- `raja` dan `ratu` hampir identik di semua dimensi, kecuali d_4 yang berlawanan tanda.

Word2Vec: Cara Melatih Embedding

"Kamu dinilai dari teman-temanmu"

Ide utama Word2Vec: sebuah kata bisa dipahami maknanya dari kata-kata *di sekitarnya*.

"Saya tadi minum _____ di warung kopi."
Kata apa yang masuk akal? ⇒ **kopi**, **teh**, **susu** — bukan **mobil** atau **gunung**.

Word2Vec melatih model untuk **menebak kata yang hilang** dari konteks kalimat. Kata-kata dengan konteks serupa otomatis mendapat **vektor yang mirip**.

CBOW (*Continuous Bag of Words*)
Konteks → tebak kata tengah
`[minum, di, warung]` → `kopi`

Skip-Gram
Kata tengah → tebak konteks
`kopi` → `[minum, di, warung]`

Hasil Training

Model tidak pernah diajarkan "kopi dan teh itu mirip" — ia **menemukan sendiri** lewat jutaan kalimat.

Dari 300 Dimensi ke 2 Dimensi

Visualisasi dengan PCA / t-SNE

Vektor 300 dimensi **tidak mungkin** kita gambar langsung.
Solusi: **kompres** ke 2 dimensi sambil mempertahankan struktur kedekatan antarkata.

Ruang asli (300 dim):

```
raja = [0.82, -0.41, ...]
ratu = [0.79, -0.38, ...]
kopi = [-0.10, 0.12, ...]
⋮
```

Setelah PCA / t-SNE (2 dim):

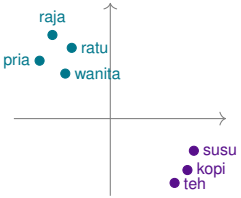

- **PCA**: proyeksi linear, cepat, bagus untuk gambaran umum.
- **t-SNE**: non-linear, lebih bagus memunculkan klaster, tapi lebih lambat.
- Kedua metode ini hanya untuk **visualisasi** — bukan untuk training.

Sifat Ajaib Word Embedding

Matematika dengan makna kata

Karena kata direpresentasikan sebagai vektor, kita bisa melakukan **operasi matematika** pada *makna*:

$$\vec{\texttt{raja}} - \vec{\texttt{pria}} + \vec{\texttt{wanita}} \approx \vec{\texttt{ratu}}$$

$$\vec{\texttt{Paris}} - \vec{\texttt{Prancis}} + \vec{\texttt{Indonesia}} \approx \vec{\texttt{Jakarta}}$$

Apa artinya ini?

- Embedding menangkap **relasi** antar konsep, bukan hanya kata.
- Konsep "jenis kelamin" dan "ibu kota" bisa dihitung seperti aritmetika biasa.

Bagaimana ini terjadi?

Murni dari jutaan kalimat — model tidak pernah diajarkan konsep "ibu kota" secara eksplisit. Pola itu **muncul sendiri**.

Ringkasan: One-Hot vs Word Embedding

Lompatan besar dalam representasi teks

	One-Hot / TF-IDF	**Word Embedding**
Ukuran vektor	50.000+ (sparse)	100–300 (dense)
Sinonim	Tidak dikenal	Posisi berdekatan
Konteks	Diabaikan	Tertangkap lewat training
Matematika makna	Tidak bisa	Raja − Pria + Wanita = Ratu
Cara dapat	Manual (hitung frekuensi)	Dilatih dari corpus besar
Contoh populer	—	Word2Vec, GloVe, FastText

Word Embedding adalah **pondasi** hampir semua model NLP modern.
Selanjutnya: bagaimana embedding ini dipakai oleh RNN, LSTM, dan Transformer.

Dari MLP ke Model Sekuensial

Masalah MLP untuk Teks

Kenapa jaringan biasa tidak cukup?

Bayangkan kamu diminta menebak makna kalimat ini:

*"Saya **tidak** baik-baik saja"*

vs.

*"Saya baik-baik saja, **tidak** ada yang salah"*

MLP melihat kedua kalimat hanya sebagai **kumpulan kata** — kata "tidak" dan "baik" ada di keduanya. Ia **tidak peduli** urutan.

Inti Masalah

Teks adalah data **berurutan** (*sequential*). Makna sebuah kata bergantung pada kata sebelumnya.

RNN — Membaca Kata Satu per Satu

Seperti kamu membaca kalimat dari kiri ke kanan

RNN (*Recurrent Neural Network*) membaca teks **kata demi kata**, sambil menyimpan "ingatan" dari kata yang sudah dibaca.

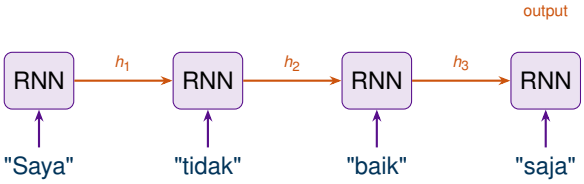

h_t = **hidden state** — semacam "catatan" yang diteruskan dari satu kata ke kata berikutnya.

Hidden State: "Memori" RNN

Informasi yang dibawa dari kata ke kata

Setiap langkah, RNN menghitung hidden state baru:

$$h_t = \tanh(W_h \cdot h_{t-1} + W_x \cdot x_t + b)$$

- h_{t-1} = ingatan dari kata sebelumnya
- x_t = kata saat ini (dalam bentuk vektor)
- Hasilnya h_t diteruskan ke langkah berikutnya

Analogi

Bayangkan kamu membaca novel sambil memegang **catatan kecil**. Setiap halaman, kamu update catatanmu. Di akhir bab, catatanmu merangkum semua yang terjadi.

Masalah RNN: "Lupa" Teks Panjang

Vanishing Gradient — musuh utama RNN

RNN bekerja bagus untuk kalimat pendek. Tapi untuk teks panjang, ada masalah besar:

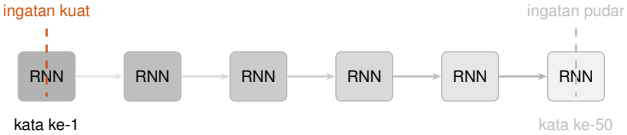

Saat proses belajar (*backpropagation*), sinyal kesalahan yang dikirim ke belakang **semakin mengecil** tiap langkah — sampai akhirnya hampir nol.

Akibatnya: RNN "lupa" kata-kata yang jauh di awal kalimat.

LSTM: Solusi untuk Ingatan Jangka Panjang

Long Short-Term Memory

LSTM menambahkan mekanisme **gerbang** (*gate*) — seperti filter yang memutuskan:

- Apa yang perlu **diingat** dari masa lalu
- Apa yang boleh **dilupakan**
- Apa yang perlu **dikeluarkan** sebagai output

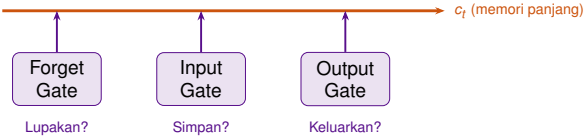

Analogi

Seperti membaca buku dengan dua catatan: **catatan panjang** (ingatan penting) dan **catatan kerja** (konteks saat ini).

BiLSTM: Membaca Dua Arah

Bidirectional LSTM

Dalam bahasa, konteks datang dari **dua arah**. Contoh:

"Saya _____ sekali hari ini" — kata apa yang cocok?

Kita butuh tahu kata sebelum *dan* sesudah celah itu.

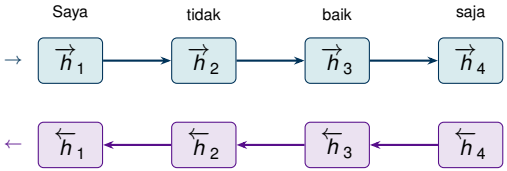

Output tiap kata = **gabungan** hidden state maju ($\overrightarrow{h}$) dan mundur ($\overleftarrow{h}$) — konteks dari dua sisi.

Word Embedding: Mengubah Kata Menjadi Angka

Representasi kata yang "memahami" makna

RNN tidak bisa langsung membaca kata — kita harus mengubahnya ke angka terlebih dahulu.

One-Hot Encoding (Cara Lama)

Kata	Vektor			
"kucing"	1	0	0	0
"anjing"	0	1	0	0
"mobil"	0	0	1	0

Masalah: "kucing" dan "anjing" **sama jauhnya** dengan "mobil" — model tidak tahu keduanya sama-sama hewan.

Embedding Layer (Cara DL)

Kata	dim-1	dim-2
"kucing"	0.82	−0.11
"anjing"	0.79	−0.08
"mobil"	−0.50	0.65

"kucing" dan "anjing" **berdekatan** — model belajar bahwa keduanya serupa.

Arsitektur BiLSTM di Workshop Ini

Gambaran model yang akan kita latih

Ringkasan Alur

Teks → indeks → embedding
→ BiLSTM 2 arah → prediksi kelas

Ukuran Model

≈7 juta parameter — lebih kecil dari BERT, cukup untuk 7 kelas.

Rangkuman: RNN vs LSTM vs BiLSTM

Evolusi arsitektur sekuensial

Aspek	**RNN**	**LSTM**	**BiLSTM**
Baca urutan	✓	✓	✓
Ingatan jangka panjang	×	✓	✓
Konteks mundur (kanan→kiri)	×	×	✓
Kompleksitas	Rendah	Sedang	Sedang–Tinggi

Kesimpulan

Untuk teks yang nuansanya halus (seperti dataset mental health kita), **BiLSTM** adalah pilihan yang jauh lebih baik dari RNN biasa.

Attention Mechanism

Masalah BiLSTM Murni

Last hidden state menanggung beban terlalu berat

Pada BiLSTM murni, setelah semua kata dibaca, **hanya satu vektor terakhir** yang diteruskan ke classifier.

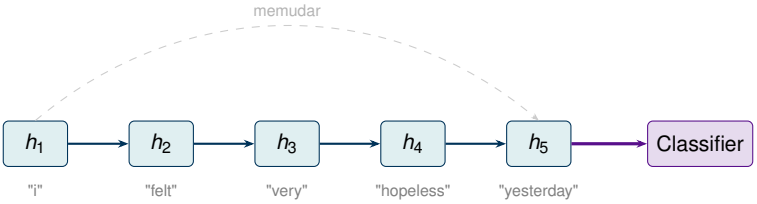

Kata *"hopeless"* di posisi ke-4 sudah **terkompresi** dan bercampur saat sampai ke posisi ke-5. Informasinya bisa memudar — terutama pada kalimat yang sangat panjang.

Solusi: Beri Model Kemampuan "Menyorot"

Ide dasar Attention Mechanism

Daripada hanya memakai *last hidden state*, bagaimana kalau model boleh **melihat semua hidden state** sekaligus dan memilih mana yang paling penting?

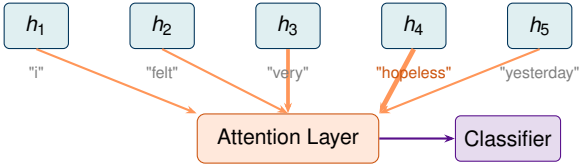

Panah yang lebih tebal = bobot attention yang lebih besar. Kata *"hopeless"* mendapat perhatian lebih dari model.

Cara Kerja Attention: Step by Step

Bahdanau Attention — langkah demi langkah

1. **BiLSTM menghasilkan hidden state** tiap kata: $h_1, h_2, \ldots, h_T$
2. **Hitung skor** — seberapa penting kata ini? $e_t = \tanh(W \cdot h_t + b)$
3. **Normalisasi** dengan Softmax (total = 1): $\alpha_t = \dfrac{\exp(e_t)}{\sum_{k=1}^{T} \exp(e_k)}$
4. **Buat context vector** — rata-rata tertimbang: $c = \sum_{t=1}^{T} \alpha_t \cdot h_t$

c inilah yang diteruskan ke classifier — merangkum seluruh kalimat dengan **penekanan lebih pada kata yang penting**.

Contoh Nilai α (Bobot Attention)

Apa yang "dilihat" model pada sebuah kalimat

Kalimat: *"i felt very hopeless and tired yesterday"*

Prediksi model: `Depression` dengan bobot attention:

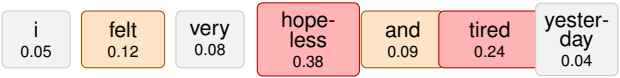

Yang Model Fokuskan

hopeless ($\alpha = 0.38$) dan *tired* ($\alpha = 0.24$) — kata-kata yang paling menunjukkan kondisi depresi.

Manfaat Explainability

Kita bisa **menjelaskan** mengapa model memprediksi kelas tertentu — penting untuk aplikasi kesehatan.

BiLSTM Murni vs BiLSTM + Attention

Apa bedanya secara arsitektur?

BiLSTM Murni

1. Baca semua kata dua arah
2. Ambil **hidden state terakhir**
3. Masukkan ke FC + Softmax

Cepat, tapi info awal bisa memudar.

BiLSTM + Attention

1. Baca semua kata dua arah
2. Hitung **skor tiap hidden state**
3. Buat *context vector* c
4. Masukkan c ke FC + Softmax

Lebih akurat **dan** bisa dijelaskan.

Aspek	**BiLSTM**	**BiLSTM+Att.**
Teks panjang	Cukup baik	Lebih baik
Explainability	×	✓
Kecepatan train	Lebih cepat	Sedikit lambat
Parameter ekstra	—	W, b kecil

Transfer Learning & Transformers

Paradigma Transfer Learning

Belajar sekali, pakai berkali-kali

Bayangkan kamu sudah mahir membaca dan memahami teks bahasa Inggris. Ketika guru memberi soal analisis puisi, kamu **tidak belajar membaca dari nol** lagi — kemampuan itu sudah ada.

Transfer Learning di NLP bekerja persis seperti itu:

1. **Pre-train**: model dilatih pada data raksasa (miliaran kalimat) tanpa label khusus — model belajar *memahami bahasa*.
2. **Fine-tune**: model yang sudah "pintar" itu kita arahkan ke tugas spesifik kita — klasifikasi 7 kelas mental health — dengan data yang jauh lebih kecil.

Analogi

Seperti **dokter umum** yang melanjutkan spesialisasi. Ia tidak belajar anatomi dari awal — ilmu dasarnya sudah ada, tinggal dalami bidang tertentu.

Pre-train → Fine-tune: Dua Fase

Cara model besar menjadi berguna untuk tugas kita

Keunggulan

- Training kita jauh **lebih cepat**
- Butuh data berlabel **lebih sedikit**
- Performa biasanya **lebih baik**

Model Pre-trained Populer

BERT, DistilBERT, RoBERTa, GPT, T5 — semua bisa di-*fine-tune* untuk tugas kita.

Transformer: Model yang Mengubah Segalanya

Lahir dari paper *"Attention is All You Need"* (Vaswani et al., 2017)

RNN dan LSTM membaca kata **satu per satu** — proses berurutan dan lambat.

Transformer hadir dengan ide revolusioner:

"Bagaimana kalau semua kata dibaca *sekaligus*?"

Tiga komponen kunci Transformer:

Self-Attention

Setiap kata bisa "melihat" semua kata lain secara langsung — tidak perlu rantai.

Positional Encoding

Karena dibaca paralel, model perlu sinyal posisi agar tahu urutan kata.

Token [CLS]

Token spesial di awal kalimat yang merangkum maknanya — dipakai untuk klasifikasi.

Dampak: Transformer menjadi fondasi BERT, GPT, T5, LLaMA, dan hampir semua model NLP terkuat saat ini.

Self-Attention: Setiap Kata Melihat Semua Kata

Inilah kekuatan utama Transformer

Kalimat: *"The **bank** by the **river** is flooded"*

Kata *bank* perlu "tahu" bahwa ia berada di dekat *river* agar model memilih makna **tepi sungai**, bukan **lembaga keuangan**.

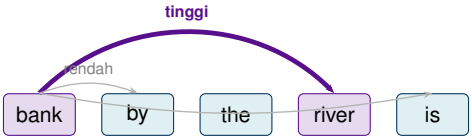

Self-Attention menghitung skor keterkaitan menggunakan tiga vektor: **Q**uery, **K**ey, **V**alue.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Sederhananya: Q = "apa yang saya cari?", K = "apa yang tersedia?", V = "informasi yang dibagi".

Positional Encoding & Token [CLS]

Dua komponen pendukung Transformer

Positional Encoding

Transformer membaca semua kata *paralel* — ia tidak tahu mana kata ke-1 atau ke-5.

Solusi: tambahkan **sinyal posisi** ke setiap embedding kata.

"kucing makan tikus" $\neq$ "tikus makan kucing"

Tanpa positional encoding, kedua kalimat dianggap identik!

Token [CLS]

Token spesial yang disisipkan di **awal setiap kalimat**.

Setelah melalui semua layer Transformer, representasi **[CLS]** merangkum makna seluruh kalimat.

[CLS] inilah yang diteruskan ke classifier untuk menentukan label akhir.

[CLS] | i | felt | hope- | less

↓ ke classifier

DistilBERT: BERT yang Lebih Ramping

97% kemampuan BERT, 40% lebih kecil, 60% lebih cepat

BERT adalah model Transformer yang dilatih Google pada dataset raksasa — hasilnya sangat kuat untuk berbagai tugas NLP.

Masalahnya: BERT sangat besar dan lambat. **DistilBERT** hadir sebagai solusinya:

Aspek	**BERT-base**	**DistilBERT**
Jumlah parameter	110 juta	**67 juta** (-40%)
Kecepatan inference	$1\times$ (acuan)	**$1.6\times$ lebih cepat**
Akurasi (benchmark NLP)	100% (acuan)	**97%** dari BERT
Ukuran file	$\approx$440 MB	$\approx$**250 MB**

Knowledge Distillation

DistilBERT dilatih dengan cara "meniru cara berpikir" BERT, bukan hanya meniru jawaban akhirnya. Teknik ini disebut **knowledge distillation** — seperti murid belajar dari *proses penalaran* gurunya.

Fine-Tuning DistilBERT untuk 7 Kelas

Freeze backbone, latih classification head

Strategi yang dipakai: **freeze backbone** + tambahkan lapisan klasifikasi baru.

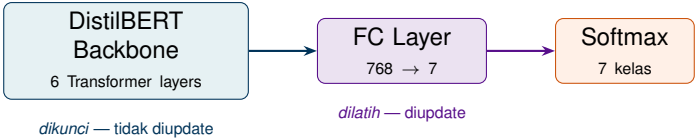

Freeze Backbone

Parameter DistilBERT **dikunci** — tidak berubah. Kita hanya melatih lapisan FC yang baru ditambahkan.

Keuntungan

- Training jauh **lebih cepat**
- Tidak perlu GPU terlalu kuat
- Mencegah *catastrophic forgetting*

Perbandingan Parameter: BiLSTM vs DistilBERT

Skala berbeda — implikasi berbeda

BiLSTM+Att. (≈7M)

- Ringan, cepat dilatih dari nol
- Cocok untuk resource terbatas
- Perlu cukup data berlabel

DistilBERT (≈67M)

- Backbone sudah "tahu bahasa"
- Butuh GPU, tapi fine-tune cepat
- Umumnya performa lebih tinggi

Perbandingan Final: BiLSTM vs DistilBERT

Kapan pilih yang mana?

Aspek	BiLSTM	BiLSTM+Att.	DistilBERT
Parameter	≈7M	≈7M	≈67M
Perlu GPU kuat	Tidak	Tidak	Disarankan
Pakai pre-trained	×	×	✓
Butuh data berlabel besar	Iya	Iya	Tidak harus
Explainability	×	✓(heatmap)	Terbatas
Akurasi pada 7 kelas	Baik	Lebih baik	Terbaik

Panduan Memilih

Resource terbatas / perlu explainability → BiLSTM + Attention.
Butuh performa terbaik / ada GPU → DistilBERT.

BERT vs DistilBERT

BERT: Guru Besar Bahasa

Bidirectional Encoder Representations from Transformers

BERT dilatih Google pada hampir seluruh Wikipedia + jutaan buku.
Dua hal unik yang membuatnya revolusioner:

1. Baca Dua Arah (Bidirectional)

Model sebelumnya (GPT) membaca kiri ke kanan saja.

BERT membaca **kiri dan kanan sekaligus**.

`saya ____ kopi`

← dan → diperhatikan

2. Masked Language Model

Saat pre-training, BERT **menyembunyikan** 15% kata secara acak, lalu menebaknya dari konteks kiri dan kanan sekaligus.

`saya [MASK] kopi` → `suka`

Hasil

BERT memecahkan rekor di 11 tugas NLP saat dirilis (2018). Masalahnya? **110 juta parameter**, butuh GPU besar, dan lambat untuk produksi.

Masalah BERT di Dunia Nyata

Terlalu besar, terlalu lambat

BERT sangat canggih — tapi ada harga yang harus dibayar:

Masalah	BERT-base	Dampak
Jumlah layer	12 layer Transformer	Lambat
Parameter	110 juta	File 440 MB
RAM saat inference	$\sim$1.5 GB	Tidak bisa di HP
Waktu per prediksi	$\sim$5 ms	Sulit real-time

Pertanyaan

Bisakah kita buat model yang **hampir secerdas BERT** tapi jauh **lebih kecil dan cepat**?

Jawabannya datang dari tim Hugging Face pada 2019:

Knowledge Distillation $\rightarrow$ DistilBERT

Knowledge Distillation: Murid Belajar dari Guru

Bukan meniru jawaban — meniru cara berpikir

Bayangkan dua cara belajar:

Cara Biasa (Hard Label)

Guru cuma bilang:

*"Kalimat ini = kelas **Depressed**."*

Murid hanya tahu jawaban akhir — tidak tahu *kenapa*.

Distillation (Soft Label)

Guru bilang:

"Ini 70% Depressed, 20% Anxiety, 10% Normal."

Murid belajar dari **pola kepercayaan** guru — jauh lebih kaya informasi.

Cara Kerja Distilasi: 3 Sinyal Sekaligus

DistilBERT dilatih dengan tiga sumber belajar

Saat melatih DistilBERT, loss gabungan dari **tiga sinyal**:

1. **Distillation Loss** — seberapa mirip distribusi probabilitas output DistilBERT dengan BERT.
   Pakai *temperature softmax*: output BERT "dilunakkan" agar perbedaan kecil antar kelas tetap terlihat.
2. **MLM Loss** — DistilBERT tetap dilatih menebak kata yang disembunyikan (*masked language model*) seperti BERT.
3. **Cosine Embedding Loss** — vektor tersembunyi DistilBERT diarahkan sedekat mungkin dengan vektor BERT.

Hasilnya: DistilBERT bukan sekadar "BERT yang dipotong" — ia punya *pemahaman bahasa* yang hampir setara, hanya lebih kompak.

Arsitektur: BERT vs DistilBERT

Setengah layer, akurasi tetap terjaga

Komponen	BERT-base	DistilBERT
Transformer layers	12	**6**
Hidden size	768	768
Attention heads	12	12
Parameter	110 juta	**67 juta**
Token type embeddings	Ada	**Dihapus**
Pooler layer	Ada	**Dihapus**
Inference speed	$1\times$	**1.6**$\times$
GLUE score	79.6	**77.0** (-3.5%)

Intuisi

Bukan semua layer itu sama pentingnya. DistilBERT membuktikan bahwa **6 layer yang terlatih dengan benar** bisa sehebat 12 layer biasa.

Perubahan utama: layer 12 $\rightarrow$ 6, token type embedding & pooler **dihapus**, hidden size & head **dipertahankan**.

Ringkasan: Pilih BERT atau DistilBERT?

Tidak ada yang selalu lebih baik — tergantung konteks

Situasi	BERT	DistilBERT
Butuh akurasi absolut tertinggi	✓	
Deployment di server terbatas		✓
Inferensi real-time (<5ms)		✓
Fine-tuning cepat dengan RAM kecil		✓
Riset / benchmark akademis	✓	
Aplikasi mobile / edge device		✓

Untuk workshop ini: DistilBERT dipilih karena lebih **ramah resource**, bisa berjalan di laptop biasa, dan perbedaan akurasinya dengan BERT sangat kecil ($< 4\%$) untuk tugas klasifikasi teks.

Ekosistem: BERT, DistilBERT, RoBERTa, DeBERTa, ALBERT, ModernBERT — semua keluarga encoder Transformer yang bisa di-fine-tune dengan cara serupa.