TERMS OF REFERENCE

TUGAS BESAR

SD25-32202 — Pemrosesan Bahasa Alami

Institut Teknologi Sumatera • Semester Genap 2025/2026

Dosen: Martin C.T. Manullang • informatika-itera.github.io/mct-nlp

Deskripsi Umum

Tugas Besar ini dirancang untuk melatih mahasiswa dalam membandingkan dua pendekatan utama dalam *Natural Language Processing* (NLP): **Machine Learning (ML)** menggunakan *AutoML framework* PyCaret, dan **Deep Learning (DL)**. Mahasiswa diharapkan menerapkan kedua teknik pada satu dataset yang sama, mengevaluasi performa masing-masing, mendeploy model ke Hugging Face Spaces, dan mendokumentasikan seluruh proses dalam sebuah paper ilmiah berformat ArXiv.

Ringkasan Tugas:

- Pilih **satu dataset NLP** (klasifikasi teks, analisis sentimen, NER, dsb.)
- Bangun model **ML** dengan **PyCaret**
- Bangun model **DL** (LSTM, Transformer, BERT fine-tuning, dsb.)
- Deploy **dua model** ke **Hugging Face Spaces**
- Tulis dan publikasikan **paper** berformat LaTeX ArXiv
- Simpan semua kode dan kontribusi di **repositori GitHub publik**

Ketentuan Kelompok

- Setiap kelompok terdiri dari **3 orang mahasiswa**.
- Pembagian tugas harus merata dan tercermin dari *commit history* di GitHub.
- Semua anggota kelompok wajib berkontribusi aktif: kontribusi individu **dinilai berdasarkan commit** pada repositori.

Luaran yang Diharapkan

1. Repositori GitHub Publik

- Repositori bersifat **publik** dan harus sudah dibuat sebelum *checkpoint* pertama.
- Nama repositori menggunakan format: `pba2026-[nama-kelompok]`
- Dosen dapat sewaktu-waktu **mengecek repositori** di setiap *checkpoint* untuk melihat progress pengerjaan — aktivitas repositori (commit, push, branch) **menjadi bagian dari penilaian**.

2. Dua Deployment di Hugging Face Spaces

- **Deployment 1**: Demo model ML (PyCaret) dengan antarmuka interaktif (Gradio atau Streamlit).
- **Deployment 2**: Demo model DL dengan antarmuka interaktif (Gradio atau Streamlit).
- Setiap deployment harus memiliki deskripsi yang jelas di halaman Hugging Face.
- Link ke kedua deployment **wajib dicantumkan** di `README.md` repositori dengan label yang jelas (*ML Model* dan *DL Model*).

3. Paper Ilmiah (Format LaTeX ArXiv)

Paper merupakan laporan **benchmark** yang membandingkan beberapa algoritma *machine learning* (via PyCaret AutoML) dengan satu model *deep learning* pada kasus klasifikasi teks yang dipilih. Tujuannya adalah menjawab: *manakah pendekatan yang lebih unggul pada dataset dan kasus ini?*

- Ditulis menggunakan template LaTeX ArXiv (`arxiv style` atau `NeurIPS/ACL`).
- Paper wajib di-*publish* ke arXiv.org (bukan hanya submitted) dan link arXiv **wajib dicantumkan** di `README.md`.
- Panjang paper: **4–8 halaman** (tidak termasuk referensi).

Ketentuan Kepengarangan (Authorship):

- Urutan *author*: **mahasiswa (posisi 1–3)** diikuti seluruh dosen pengampu, dengan **Martin C.T. Manullang sebagai author terakhir** (*corresponding author*).
- Afiliasi seluruh author: Institut Teknologi Sumatera (ITERA).
- Email yang digunakan adalah email ITERA resmi (`[nim]@student.itera.ac.id` untuk mahasiswa, `[nama]@itera.ac.id` untuk dosen).

Format Judul: Judul paper ditulis dalam **Bahasa Inggris** dan harus memuat: nama algoritma ML yang digunakan, nama arsitektur DL, dan kasus klasifikasi. Contoh judul:

> *"Benchmarking PyCaret AutoML Against BiLSTM for Sentiment Analysis on Indonesian Product Reviews"*
>
> *"A Comparative Study of Random Forest, SVM, and BERT Fine-Tuning for Fake News Detection"*
>
> *"Machine Learning vs. Deep Learning for Toxic Comment Classification: A PyCaret and IndoBERT Benchmark"*

Struktur paper yang direkomendasikan:

Bagian	Isi
Abstract	Ringkasan dataset, metode, dan hasil benchmark
Introduction	Latar belakang, motivasi, dan kontribusi
Related Work	Referensi terkait dataset dan teknik yang digunakan
Dataset	Deskripsi dataset, statistik, dan preprocessing
Methodology	Pipeline ML (PyCaret, beberapa algoritma) dan arsitektur DL
Experiments	Konfigurasi eksperimen, hyperparameter, metrik evaluasi
Results & Discussion	Tabel benchmark semua model, analisis komparatif
Conclusion	Kesimpulan: model terbaik dan alasannya
References	Minimal 10 referensi ilmiah

Ketentuan Pemilihan Dataset

- Dataset harus relevan dengan tugas NLP (klasifikasi teks, analisis sentimen, deteksi spam, NER, dsb.).
- Dataset tidak boleh sama antar kelompok — didaftarkan via form Tally pada *checkpoint* pertama.
- Sumber dataset yang disarankan:
  - Hugging Face Datasets
  - Kaggle
  - Papers with Code
  - Dataset Bahasa Indonesia (IndoNLU, SMSA, NusaX, dsb.)
- Pastikan dataset memiliki jumlah sampel yang cukup representatif untuk tugas klasifikasi yang dipilih.

Teknik yang Digunakan

Machine Learning dengan PyCaret

- Gunakan modul `pycaret.classification` (sesuai tugas).
- Bandingkan **3 algoritma** ML, pilih dan evaluasi model terbaik.
- Dokumentasikan preprocessing, feature engineering (TF-IDF, BoW, dsb.), dan evaluasi.

Deep Learning

- Pilih arsitektur DL yang sesuai (LSTM, GRU, CNN-text, BERT fine-tuning, dsb.) — **bebas**, namun total parameter model **tidak boleh melebihi 10 juta parameter (10M)**.
- Framework wajib menggunakan **PyTorch**.
- Dokumentasikan arsitektur, jumlah parameter, hyperparameter training, dan kurva pelatihan.

Jadwal dan Checkpoint

Checkpoint 1 — 18 Maret 2026

Target: Pemilihan dan pelaporan dataset

Deliverable:

- Isi form Tally berikut: `tally.so/r/9q1xKK`
  Form meminta informasi berikut:
  - **NIM** seluruh anggota kelompok (3 orang)
  - **Link repositori GitHub** (buat repo kosong terlebih dahulu, bersifat publik)
  - **Link dataset** yang dipilih
  - **Penjabaran model**: apa yang ingin diklasifikasi dari dataset tersebut
- Repositori GitHub publik sudah dibuat dengan nama format `pba2026-[nama-kelompok]` (minimal berisi `README.md` dan struktur folder awal).

Dosen akan mengecek repositori GitHub untuk memverifikasi bahwa repo sudah dibuat dan publik.

Checkpoint 2 — 8 April 2026

Target: Model ML dengan PyCaret selesai

Deliverable:

- Notebook EDA dan preprocessing selesai (di-*commit* ke GitHub).
- Notebook PyCaret AutoML selesai: benchmark 3 algoritma ML, evaluasi, dan pilih model terbaik.
- Demo ML sudah di-deploy ke Hugging Face Spaces dan **link dicantumkan di** `README.md`.

Dosen dapat mengecek repositori GitHub untuk memverifikasi progress pada tanggal ini.

Checkpoint 3 — 22 April 2026

Target: Model Deep Learning selesai

Deliverable:

- Notebook DL selesai dengan training log dan evaluasi (di-*commit* ke GitHub).
- Demo DL sudah di-deploy ke Hugging Face Spaces dan **link dicantumkan di** `README.md`.

Dosen dapat mengecek repositori GitHub untuk memverifikasi progress pada tanggal ini.

Checkpoint 4 (Final) — 29 April 2026

Target: Report selesai dan dipublikasikan ke arXiv

Deliverable:

- Paper lengkap (LaTeX) sudah di-submit ke arXiv.org dan statusnya *published* (bukan hanya submitted).
- `README.md` repositori memuat ketiga tautan berikut secara eksplisit:
  - Link **Hugging Face Spaces — ML model** (PyCaret)
  - Link **Hugging Face Spaces — DL model**
  - Link **arXiv paper** yang sudah *published*
- Semua kode, notebook, dan file paper (`paper/main.tex`) ada di repositori GitHub.

Rubrik Penilaian

Penilaian Kelompok

Komponen	Keterangan	Bobot
Dataset & EDA	Kualitas eksplorasi data dan preprocessing	10%
Model ML (PyCaret)	Kelengkapan AutoML, evaluasi, perbandingan algoritma	20%
Model DL	Kesesuaian arsitektur, training, evaluasi	20%
Deployment HF	Fungsionalitas & kualitas antarmuka kedua demo	15%
Paper ArXiv	Kualitas tulisan, analisis komparatif, referensi	25%
Repositori GitHub	Struktur, dokumentasi (`README`), kelengkapan	10%
Total		**100%**

Penilaian Individu

Kontribusi individu dinilai berdasarkan:

- **Commit history** di GitHub: jumlah, kualitas, dan konsistensi commit.
- Setiap anggota diharapkan memiliki kontribusi *commit* yang signifikan dan merata.
- Anggota yang tidak memiliki commit akan mendapat nilai **0** untuk komponen individu.

Perhatian

Kelompok yang terbukti menggunakan kode orang lain tanpa atribusi, atau commit dilakukan oleh satu orang untuk semua anggota, akan dikenakan sanksi akademik sesuai peraturan ITERA.

Cara Pengumpulan

1. Buat repositori GitHub **publik** dengan nama format: `pba2026-[nama-kelompok]`
2. Desain `README.md` dengan **rapi dan informatif**. README wajib memuat:
   - **Judul proyek** dan deskripsi singkat tugas klasifikasi yang diselesaikan
   - **Tabel anggota kelompok** dengan kolom: Nama, NIM, dan Username GitHub

- Deskripsi singkat dataset yang digunakan
- **Link HF Spaces — ML Model** (hasil PyCaret)
- **Link HF Spaces — DL Model** (PyTorch)
- **Link arXiv** paper yang sudah *published*

3. Daftarkan kelompok dan dataset melalui form Tally `tally.so/r/9q1xKK` pada Checkpoint 1.

Contoh tabel anggota pada `README.md`:

```
| Nama | NIM | GitHub |
| -- | -- | --- |
| Budi Santoso | 121450001 | @budisantoso |
| Sari Dewi | 121450002 | @saridewi |
| Andi Pratama | 121450003 | @andipratama |
```

Tips dan Sumber Daya

- **PyCaret NLP**: pycaret.gitbook.io/docs
- **Hugging Face Spaces**: huggingface.co/docs/hub/spaces
- **Template LaTeX ArXiv**: arxiv.org/help/submit_latex — gunakan `ar5iv` style atau template konferensi (ACL, EMNLP)
- **Dataset Bahasa Indonesia**: IndoNLU (github.com/indobenchmark/indonlu), NusaX
- Gunakan **Google Colab** atau **Kaggle Notebooks** untuk training jika tidak memiliki GPU.

Dokumen ini berlaku sebagai panduan resmi Tugas Besar SD25-32202 Pemrosesan Bahasa Alami, Semester Genap 2025/2026. Pertanyaan dapat diajukan melalui saluran komunikasi resmi kelas.

Lampung Selatan, Maret 2026

Martin C.T. Manullang
Dosen Pengampu
SD25-32202 Pemrosesan Bahasa Alami

LAMPIRAN

Checklist Progress Tugas Besar

SD25-32202 Pemrosesan Bahasa Alami — Semester Genap 2025/2026

Gunakan lembar ini untuk mentrack progres pengerjaan kelompok. Centang (✓) setiap item yang sudah diselesaikan.

Checkpoint 1 — 18 Maret 2026: Dataset & Registrasi

- ☐ Sepakati dataset yang akan digunakan bersama kelompok
- ☐ Sepakati tugas klasifikasi: apa yang akan diprediksi/diklasifikasi
- ☐ Buat repositori GitHub publik dengan nama `pba2026-[nama-kelompok]`
- ☐ Buat `README.md` awal berisi tabel anggota (Nama, NIM, Username GitHub)
- ☐ Isi form Tally: `tally.so/r/9q1xKK` (NIM anggota, link repo, link dataset, penjabaran model)

Checkpoint 2 — 8 April 2026: Model ML (PyCaret)

- ☐ Download dan eksplorasi dataset (EDA)
- ☐ Lakukan preprocessing teks (cleaning, tokenisasi, feature extraction)
- ☐ Jalankan PyCaret dan bandingkan 3 algoritma ML
- ☐ Pilih model terbaik dan simpan/export model
- ☐ Buat aplikasi demo (Gradio/Streamlit) untuk model ML
- ☐ Deploy demo ML ke Hugging Face Spaces
- ☐ Update `README.md`: tambahkan link HF Spaces — ML Model
- ☐ Commit semua notebook dan kode ke repositori GitHub

Checkpoint 3 — 22 April 2026: Model Deep Learning (PyTorch)

- ☐ Tentukan arsitektur DL yang akan digunakan
- ☐ Verifikasi jumlah parameter model $\leq$ 10 juta parameter
- ☐ Implementasi model dengan **PyTorch**
- ☐ Latih model dan catat kurva training/validation loss
- ☐ Evaluasi model DL pada data uji
- ☐ Buat aplikasi demo (Gradio/Streamlit) untuk model DL
- ☐ Deploy demo DL ke Hugging Face Spaces
- ☐ Update `README.md`: tambahkan link HF Spaces — DL Model
- ☐ Commit semua notebook dan kode ke repositori GitHub

Checkpoint 4 (Final) — 29 April 2026: Paper ArXiv

- ☐ Tentukan judul paper (Bahasa Inggris, memuat nama algoritma ML, arsitektur DL, dan kasus)
- ☐ Susun urutan author: mahasiswa (1–3), dosen lain, Martin C.T. Manullang (terakhir)
- ☐ Tulis bagian *Abstract* dan *Introduction*
- ☐ Tulis bagian *Related Work* (min. 10 referensi)
- ☐ Tulis bagian *Dataset* dan preprocessing
- ☐ Tulis bagian *Methodology* (pipeline ML dan arsitektur DL)
- ☐ Tulis bagian *Experiments* (konfigurasi, hyperparameter, metrik)
- ☐ Susun tabel benchmark: bandingkan 3 model ML vs. 1 model DL
- ☐ Tulis bagian *Results & Discussion* dan *Conclusion*
- ☐ Compile paper dengan LaTeX (ArXiv/NeurIPS/ACL template)
- ☐ Submit paper ke arXiv.org dan tunggu hingga statusnya *published*
- ☐ Update `README.md`: tambahkan link arXiv paper
- ☐ Commit file paper (`paper/main.tex` + `.bib`) ke repositori GitHub
- ☐ Pastikan `README.md` lengkap dan rapi (tabel anggota, link HF $\times 2$, link arXiv)